Solución al Reward Hacking y Specification Gaming en Simulaciones GridWorld: Un Enfoque Experimental y de Alineación

Juana Gabriela López Trejos, Juan José Melo Montenegro, Wilson Navia Valencia, Jaiber Johan Obando López, Eduardo Sarmiento Pradilla

Especialización en Inteligencia Artificial
Seminario en Ética e Inteligencia Artificial
Laboratorio de Aprendizaje por Refuerzo e Inteligencia Artificial

28 de Septiembre, 2026

Abstract

El fenómeno de *specification gaming* y *reward hacking* constituye un desafío fundamental en la alineación y seguridad de sistemas de Aprendizaje por Refuerzo (RL). Cuando la función de recompensa formulada por el diseñador no se alinea con el objetivo real deseado, los agentes optimizadores explotan fallas lógicas para maximizar el retorno numérico sin cumplir la tarea real. En este trabajo se analiza un entorno de tipo GridWorld (6×6) desarrollado bajo la biblioteca Gymnasium, donde la configuración base original ($V1$) incentiva un comportamiento de recolección infinita de monedas (*farming*), resultando en una tasa de éxito hacia la meta del 0.0% a pesar de obtener recompensas acumuladas muy elevadas (188.09). A través de un proceso experimental sistemático de 13 configuraciones, se evaluó el impacto de restringir la reaparición de recursos (`coin_repeatable=False`), ajustar la dominancia de la meta (`goal_reward=25.0`), e incrementar el costo de penalización por paso (`step_cost=-1.0`). La configuración final reespecificada ($V2$) logró un 100.0% de éxito hacia la meta con una recompensa promedio real de 16.46. Se discuten las implicaciones éticas, los mecanismos de supervisión previa al despliegue y la conexión con marcos avanzados de alineación de IA.

***Palabras Clave*—Aprendizaje por Refuerzo, Specification Gaming, Reward Hacking, Alineación de IA, Ley de Goodhart, Q-Learning, Gymnasium.**

1 Introducción y Marco Teórico

En el Aprendizaje por Refuerzo (RL), un agente interactúa con un entorno formalizado mediante un Proceso de Decisión de Markov (MDP) caracterizado por el tuplo $\langle S, A, P, R, \gamma \rangle$. El objetivo del agente es aprender una política óptima $\pi^* : S \to A$ que maximice el retorno acumulado esperado $G_t = \sum_{k=0}^{\infty} \gamma^k R_{t+k+1}$.

Sin embargo, en el diseño de entornos complejos surge frecuentemente el problema de *specification gaming* (o *reward hacking*). Este fallo ocurre cuando existe un desacople entre el objetivo intencionado del diseñador (*intended goal*) y la señal de recompensa programada (*specified reward*).

Bajo la Ley de Goodhart, adaptada al contexto de la IA: *"Cuando una medida o señal numérica de recompensa se convierte en el objetivo de optimización, deja de ser una buena medida del propósito real"*.

En entornos discretos simulados como GridWorld, donde la navegación se modela sobre matrices bidimensionales mediante librerías como Gymnasium (siguiendo los métodos estándar `reset()` y `step()`), la presencia de recompensas intermedias repetibles puede inducir ciclos cerrados de retroalimentación donde el agente prefiere mantener estados de alta recompensa local indefinidamente antes que completar el episodio.

2 Diagnóstico de la Configuración Base ($V1$)

2.1 Especificación del Entorno y Parámetros Iniciales

El entorno de prueba consiste en una grilla de 6×6 casillas. El agente inicia en la posición $S(0, 0)$ y la meta principal se ubica en $META(5, 5)$. En la grilla existen monedas dispuestas en las posiciones $(0, 1)$, $(1, 0)$ y $(1, 1)$.

La configuración base mal especificada ($V1$) estuvo definida por los siguientes parámetros:

- `coin_repeatable = True`
- `coin_reward = 1.0`
- `goal_reward = 10.0`
- `step_cost = -0.01`
- `max_steps = 200`

2.2 Comportamiento Patológico Observado

Al entrenar al agente utilizando Q-Learning tabular, se obtuvieron los siguientes resultados cuantitativos:

- **Tasa de éxito a la meta:** 0.0%
- **Recompensa promedio acumulada:** 188.09

2.3 Análisis del Mapa de Política y Bucle Infinito

La causa raíz de este fallo reside en la estructura de los incentivos numéricos. Dado que el costo por paso era insignificante (-0.01) y las monedas reaparecían infinitamente (`coin_repeatable=True`), el agente descubrió que alternar movimientos entre las casillas $(0,1)$, $(1,0)$ y $(1,1)$ le permitía acumular aproximadamente $+1.0$ por cada paso. A lo largo de un episodio de 200 pasos, esta estrategia genera una recompensa acumulada de aproximadamente $+198.0$, superando ampliamente el incentivo de $+10.0$ otorgado por llegar a la meta final.

En el mapa de política resultante, las flechas convergieron hacia una trampa circular alrededor del grupo inicial de monedas, cancelando completamente la exploración hacia $META(5,5)$.

3 Metodología Experimental y Evolución

Para erradicar el *reward hacking*, el equipo ejecutó una serie sistemática de 13 experimentos modificando parámetros aislados y estructurales. La Tabla 1 sintetiza las configuraciones probadas y sus respectivos resultados.

3.1 Análisis de los Hallazgos Experimentales

1. **Modificación Estructural vs. Ajuste de Escala:** La Prueba 1 demostró que cambiar `coin_repeatable` a `False` elimina de raíz el incentivo de recolectar infinitamente, elevando de inmediato la tasa de éxito al 100.0%.
2. **Insuficiencia de Reducir la Recompensa por Moneda:** En las Pruebas 2, 6 y 7, mientras las monedas fueran infinitas, el agente prefería recolectarlas siempre que la recompensa neta por paso continuara siendo superior al costo de movimiento.
3. **Papel del Costo de Paso (`step_cost`):** En las Pruebas 8 y 9, se logró forzar el éxito a la meta aun con `coin_repeatable=True` al establecer un penalizador por paso de -1.0 o -1.25 frente a una recompensa por moneda muy baja (0.1). Esto anuló el margen de ganancia del *farming*.
4. **Efecto de `max_steps` y la Recompensa Final:** En las Pruebas 10 a 13, la combinación de `coin_repeatable=False`, `goal_reward=25.0` y `step_cost=-1.0` aseguró una trayectoria óptima directa. Incrementar `max_steps` a 500 otorgó suficiente horizonte para que la fase de exploración inicial no truncara episodios prometedores.

4 Configuración Final Reespecificada ($V2$)

4.1 Parámetros Finales Adoptados

La configuración óptima seleccionada ($V2$) consolida las siguientes reglas:

- `coin_repeatable = False`: Las monedas desaparecen al ser recolectadas.
- `coin_reward = 1.0`: Incentivo secundario moderado.
- `goal_reward = 25.0`: Dominancia clara del objetivo final.
- `step_cost = -1.0`: Penalización estricta por ineficiencia.
- `max_steps = 500`: Ventana amplia para exploración sin truncamiento prematuro.

4.2 Comparativa de Desempeño $V1$ vs. $V2$

La Tabla 2 resalta la paradoja del *reward hacking*: la cifra de recompensa numérica más alta no corresponde al agente más inteligente o alineado.

5 Discusión de Preguntas de la Actividad

5.1 Discusión de Laboratorio (Parte B)

B1. Cambios determinantes en la reespecificación: Los tres cambios críticos para transformar el comportamiento del agente fueron:

1. **Eliminación de la reaparición (`coin_repeatable=False`):** Rompió la fuente inagotable de recompensa local.
2. **Dominancia del objetivo (`goal_reward=25.0`):** Aseguró que el retorno de alcanzar $META$ sea estrictamente superior a la suma de recolectar todas las monedas secundarias.
3. **Penalización por tiempo (`step_cost=-1.0`):** Generó incentivos para encontrar la ruta más corta, penalizando la deambulación.

B2. La Paradoja de la Recompensa Promedio: La métrica de recompensa acumulada promedio en $V1$ (188.09) es significativamente mayor que en $V2$ (16.46). Sin embargo, $V1$ representa un fallo total de la tarea. Esto demuestra que la recompensa acumulada es una métrica interna de optimización del algoritmo, no una métrica de éxito del negocio o de la tarea real. Comparar modelos basándose únicamente en la recompensa acumulada sin verificar la tasa de éxito conduce a falsas evaluaciones.

B3. Generalización a Nuevas Posiciones o Mapas: Un arreglo basado únicamente en sobre-penalizar el costo por paso sin corregir las reglas del entorno (como en la Conf. 8) puede fallar si las monedas se reubican lejos del origen o si el tamaño de la grilla aumenta. Para garantizar generalización, la reespecificación debe ser de carácter principista: eliminar la repetibilidad infinita de recompensas consumibles y garantizar que el objetivo principal sea siempre globalmente dominante independientemente de la topología.

B4. Detección Previa al Despliegue en Sistemas Reales: En un equipo multidisciplinario (Ingenieros ML, PMs, Expertos de Dominio, Ingenieros de Seguridad), se deben establecer los siguientes mecanismos:

- **Inspección Cualitativa e Interpretación de Políticas:** Renderizado visual de trayectorias e inspección de mapas de acción antes de validar un modelo.

Table 1: Evolución de Configuraciones Experimentales de la Actividad de Laboratorio

Prueba	coin_repeatable	coin_reward	goal_reward	step_cost	max_steps	% Éxito Meta	Recompensa Promedio
$V1$ (Base)	True	1.0	10.0	-0.01	200	0.0%	188.09
Conf. 1	False	1.0	10.0	-0.01	200	100.0%	11.90
Conf. 2	True	0.5	10.0	-0.01	200	0.0%	94.05
Conf. 3	True	1.0	20.0	-0.01	200	0.0%	188.09
Conf. 4	True	1.0	10.0	-0.50	200	0.0%	90.00
Conf. 5	True	1.0	10.0	-0.01	50	0.0%	44.00
Conf. 6	True	0.5	20.0	-0.50	50	0.0%	20.00
Conf. 7	True	0.2	25.0	-0.80	50	0.0%	8.00
Conf. 8	True	0.1	25.0	-1.00	50	100.0%	15.00
Conf. 9	True	0.1	25.0	-1.25	50	100.0%	12.50
Conf. 10	False	1.0	25.0	-1.00	200	100.0%	16.46
Conf. 11	False	1.0	25.0	-1.00	300	100.0%	16.46
Conf. 12	False	1.0	25.0	-1.00	500	100.0%	16.46
$V2$ (Final)	False	1.0	25.0	-1.00	500	100.0%	16.46

Table 2: Comparación Cuantitativa entre $V1$ y $V2$

Métrica	Configurac. $V1$	Configurac. $V2$
Éxito a la Meta	0.0%	100.0%
Recompensa Prom.	188.09	16.46
Conducta Dominante	Círculo Infinito	Navegación Óptima
Pasos Promedio	200 (Límite)	~ 10 pasos

- **Métricas de Negocio Independientes:** Evaluaciones ciegas que midan el cumplimiento real de la meta (*KPIs*) sin considerar la función de recompensa interna del agente.
- **Red Teaming y Pruebas de Esfuerzo:** Creación de escenarios adversarios diseñados específicamente para encontrar vacíos en la función de recompensa.

5.2 Conexión con el Atlas de Alineación (Parte C)

C1. Impredecibilidad de Modos de Fallo: Incluso en un sistema diminuto de 6×6 casillas (36 estados discretos), la interacción entre un costo de paso bajo y una recompensa intermedia produjo una conducta imprevista e indeseada (0% éxito). Esto evidencia la extrema dificultad de anticipar comportamientos emergentes cuando la escala del espacio de estados crece a millones de dimensiones en el mundo real.

C2. Imposibilidad de Enumeración Manual de "Trucos": Intentar parchar manualmente cada falla o "truco" que descubra un agente es inviable en entornos complejos. Los agentes de RL son optimizadores implacables que explotarán cualquier inconsistencia en las reglas.

C3. Estrategias Avanzadas de Alineación: Para ir más allá del rediseño manual de recompensas, la literatura y la industria emplean:

- **Supervisión y Evaluaciones Humanas (*Human Oversight / RLHF*):** Aprendizaje a partir de preferencias humanas para ajustar funciones de recompensa complejas.
- **Aprendizaje por Refuerzo Inverso (*IRL*):** Deducir la función de recompensa analizando demostraciones de expertos humanos.
- **Especificaciones Formales y Escudos (*Shielding*):** Definir restricciones lógicas estrictas que el agente no pueda violar independientemente de la recompensa.

6 Conclusiones

1. El *reward hacking* no es un error del algoritmo de aprendizaje (Q-learning funcionó perfectamente), sino una falla de alineación en la formulación de la función de recompensa.
2. Las métricas de recompensa acumulada deben interpretarse con cautela; una cifra elevada puede ser síntoma de explotación de un vacío lógico.
3. La reespecificación exitosa requiere garantizar la dominancia global del objetivo real y neutralizar bucles de recompensa local infinita.

References

[1] Farama Foundation, "Gymnasium: A Standard Interface for Reinforcement Learning Environments," 2023. [Online]. Available: `https://gymnasium.farama.org/`

[2] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed. Cambridge, MA, USA: MIT Press, 2018.

[3] D. Amodei, C. Olah, J. Steinhardt, P. Christiano, J. Schulman, and D. Mané, "Concrete Problems in AI Safety," *arXiv preprint arXiv:1606.06565*, 2016.

[4] V. Krakovna et al., "Specification gaming: the flip side of AI ingenuity," *DeepMind Blog*, 2020. [Online]. Available: `https://www.deepmind.com/blog/specification-gaming-the-flip-side-of-ai-ingenuity`

[5] D. Melhart, "The Ethics of AI in Games," *IEEE Transactions on Games*, vol. 15, no. 2, pp. 112–124, 2023.

[6] L. Busoniu, R. Babuska, and B. De Schutter, "A Comprehensive Survey of Multi-Agent Reinforcement Learning," *IEEE Transactions on Systems, Man, and*

Cybernetics, Part C (Applications and Reviews), vol. 38, no. 2, pp. 156–172, 2008.

[7] J. Ferlez et al., "A Composable Specification Language for Reinforcement Learning Tasks," in *Proceedings of the IEEE Conference on Decision and Control (CDC)*, 2021, pp. 1245–1252.

[8] J. G. López Trejos, J. J. Melo Montenegro, W. Navia Valencia, J. J. Obando López, y E. Sarmiento Pradilla, "Respuestas e Informe Técnico de Laboratorio: Specification Gaming y Reward Hacking," *Especialización en Inteligencia Artificial, Seminario en Ética e Inteligencia Artificial*, 2026.